ANALYSEZ DES DONNEES DE SYSTEMES EDUCATIFS.

des données de la banque mondiale sur l'éducation

PLAN

1. Présentation du projet
2. Le jeu de données
3. Séquence de filtrage des données
4. Normalisation
5. Méthode de classement des pays
6. Géo localisation
7. Conclusion

1. Présentation du projet.

Objectif du projet: Réaliser une analyse pré-exploratoire de données de systèmes éducatifs de la Banque Mondiale pour déterminer un projet d'expansion de notre start-up à l'international

Les informations à collecter de cette étude sont:

Quels sont les pays avec un fort potentiel de clients pour nos services?

Dans quels pays l'entreprise doit-elle opérer en priorité?

2. Le jeu de données.

In [1]:
```
import pandas as pd
```

In [2]:
```
# Lecture des fichiers CSV pour remplir les DataFrame correspondants
country=pd.read_csv('EdStatsCountry.csv')
series=pd.read_csv('EdStatsSeries.csv')
country_series=pd.read_csv('EdStatsCountry-Series.csv')
data=pd.read_csv('EdStatsData.csv')
foot_note=pd.read_csv('EdStatsFootNote.csv')
```

Vérification du fichier EdStatsCountry.csv

In [3]:
```
# Affiche les 3 premières lignes du DataFrame 'country'
country.head(3)
```

Out[3]:

	Country Code	Short Name	Table Name	Long Name	2-alpha code	Currency Unit	Special Notes	Region	Income Group	WB-2 code	...	diss
0	ABW	Aruba	Aruba	Aruba	AW	Aruban florin	SNA data for 2000-2011 are	Latin America	High income: nonOECD	AW	...	

							updated from offici...	& Caribbean				
1	AFG	Afghanistan	Afghanistan	Islamic State of Afghanistan	AF	Afghan afghani	Fiscal year end: March 20; reporting period fo...	South Asia	Low income	AF	...	Ge Diss
2	AGO	Angola	Angola	People's Republic of Angola	AO	Angolan kwanza	April 2013 database update: Based on IMF data,...	Sub-Saharan Africa	Upper middle income	AO	...	Ge Diss

3 rows × 32 columns

In [4]:
```
#permet de visualiser le nom, les types de données et les remplissages des colonnes
country.info()
```

```
<class 'pandas.core.frame.DataFrame'>
RangeIndex: 241 entries, 0 to 240
Data columns (total 32 columns):
 #   Column                                            Non-Null Count  Dtype
---  ------                                            --------------  -----
 0   Country Code                                      241 non-null    object
 1   Short Name                                        241 non-null    object
 2   Table Name                                        241 non-null    object
 3   Long Name                                         241 non-null    object
 4   2-alpha code                                      238 non-null    object
 5   Currency Unit                                     215 non-null    object
 6   Special Notes                                     145 non-null    object
 7   Region                                            214 non-null    object
 8   Income Group                                      214 non-null    object
 9   WB-2 code                                         240 non-null    object
 10  National accounts base year                       205 non-null    object
 11  National accounts reference year                  32 non-null     float64
 12  SNA price valuation                               197 non-null    object
 13  Lending category                                  144 non-null    object
 14  Other groups                                      58 non-null     object
 15  System of National Accounts                       215 non-null    object
 16  Alternative conversion factor                     47 non-null     object
 17  PPP survey year                                   145 non-null    object
 18  Balance of Payments Manual in use                 181 non-null    object
 19  External debt Reporting status                    124 non-null    object
 20  System of trade                                   200 non-null    object
 21  Government Accounting concept                     161 non-null    object
 22  IMF data dissemination standard                   181 non-null    object
 23  Latest population census                          213 non-null    object
 24  Latest household survey                           141 non-null    object
 25  Source of most recent Income and expenditure data 160 non-null    object
 26  Vital registration complete                       111 non-null    object
 27  Latest agricultural census                        142 non-null    object
 28  Latest industrial data                            107 non-null    float64
 29  Latest trade data                                 185 non-null    float64
 30  Latest water withdrawal data                      179 non-null    object
 31  Unnamed: 31                                       0 non-null      float64
dtypes: float64(4), object(28)
memory usage: 60.4+ KB
```

In [5]:
```
country.describe() #resumé statistique (moyenne, la médiane, les quartiles, l'écart-type
```

Out[5]:

	National accounts reference year	Latest industrial data	Latest trade data	Unnamed: 31
count	32.00000	107.000000	185.000000	0.0
mean	2001.53125	2008.102804	2010.994595	NaN
std	5.24856	2.616834	2.569675	NaN
min	1987.00000	2000.000000	1995.000000	NaN
25%	1996.75000	2007.500000	2011.000000	NaN
50%	2002.00000	2009.000000	2012.000000	NaN
75%	2005.00000	2010.000000	2012.000000	NaN
max	2012.00000	2010.000000	2012.000000	NaN

Observations: 241 lignes, 32 colonnes, le dataset assez bien rempli, contient des informations géographiques, économiques, telles que le code ISO du pays, le nom long du pays, la région, le groupe de revenu...

Vérification du fichier EdStatsSeries.csv

In [6]:
```
series.head(3)
```

Out[6]:

	Series Code	Topic	Indicator Name	Short definition	Long definition	Unit of measure	Periodicity	Base Period	Other notes	Aggr
0	BAR.NOED.1519.FE.ZS	Attainment	Barro-Lee: Percentage of female population age...	Percentage of female population age 15-19 with...	Percentage of female population age 15-19 with...	NaN	NaN	NaN	NaN	
1	BAR.NOED.1519.ZS	Attainment	Barro-Lee: Percentage of population age 15-19 ...	Percentage of population age 15-19 with no edu...	Percentage of population age 15-19 with no edu...	NaN	NaN	NaN	NaN	
2	BAR.NOED.15UP.FE.ZS	Attainment	Barro-Lee: Percentage of female population age...	Percentage of female population age 15+ with n...	Percentage of female population age 15+ with n...	NaN	NaN	NaN	NaN	

3 rows × 21 columns

In [7]:
```
series.info()
```

```
<class 'pandas.core.frame.DataFrame'>
RangeIndex: 3665 entries, 0 to 3664
Data columns (total 21 columns):
 #   Column                                Non-Null Count  Dtype
---  ------                                --------------  -----
 0   Series Code                           3665 non-null   object
 1   Topic                                 3665 non-null   object
```

```
 2   Indicator Name                        3665 non-null   object
 3   Short definition                      2156 non-null   object
 4   Long definition                       3665 non-null   object
 5   Unit of measure                       0 non-null      float64
 6   Periodicity                           99 non-null     object
 7   Base Period                           314 non-null    object
 8   Other notes                           552 non-null    object
 9   Aggregation method                    47 non-null     object
 10  Limitations and exceptions            14 non-null     object
 11  Notes from original source            0 non-null      float64
 12  General comments                      14 non-null     object
 13  Source                                3665 non-null   object
 14  Statistical concept and methodology   23 non-null     object
 15  Development relevance                 3 non-null      object
 16  Related source links                  215 non-null    object
 17  Other web links                       0 non-null      float64
 18  Related indicators                    0 non-null      float64
 19  License Type                          0 non-null      float64
 20  Unnamed: 20                           0 non-null      float64
dtypes: float64(6), object(15)
memory usage: 601.4+ KB
```

Observations: 3665 lignes, 21 colonnes,le dataset EdStatsSeries sont des données statiques détaillées sur les 3665 indicateurs regroupés par catégories, du code de série, du sujet, de la définition longue, de l'unité de mesure, de la périodicité et du concept et de la méthodologie statistiques...Les colonnes qui définissent l'indicateurs et la colonne Source ont un taux de remplissage élevé.

Vérification du fichier Country-Series.csv

In [8]:
```
country_series.head(3)
```

Out[8]:

	CountryCode	SeriesCode	DESCRIPTION	Unnamed: 3
0	ABW	SP.POP.TOTL	Data sources : United Nations World Population...	NaN
1	ABW	SP.POP.GROW	Data sources: United Nations World Population ...	NaN
2	AFG	SP.POP.GROW	Data sources: United Nations World Population ...	NaN

In [9]:
```
country_series.info()
```

```
<class 'pandas.core.frame.DataFrame'>
RangeIndex: 613 entries, 0 to 612
Data columns (total 4 columns):
 #   Column       Non-Null Count  Dtype
---  ------       --------------  -----
 0   CountryCode  613 non-null    object
 1   SeriesCode   613 non-null    object
 2   DESCRIPTION  613 non-null    object
 3   Unnamed: 3   0 non-null      float64
dtypes: float64(1), object(3)
memory usage: 19.3+ KB
```

Observations: 613 lignes, 4 colonnes EdStatsCountry-Series.csv donne des indications entre un code de pays et ses codes indicateurs avec les références des sources. Mise à part une colonne ce Dataset est complet.

Vérification du fichier FootNote.csv

In [10]:
```
foot_note.head(3)
```

Out[10]:

	CountryCode	SeriesCode	Year	DESCRIPTION	Unnamed: 4
0	ABW	SE.PRE.ENRL.FE	YR2001	Country estimation.	NaN
1	ABW	SE.TER.TCHR.FE	YR2005	Country estimation.	NaN
2	ABW	SE.PRE.TCHR.FE	YR2000	Country estimation.	NaN

In [11]:
```
foot_note.info()
```

```
<class 'pandas.core.frame.DataFrame'>
RangeIndex: 643638 entries, 0 to 643637
Data columns (total 5 columns):
 #   Column        Non-Null Count   Dtype
---  ------        --------------   -----
 0   CountryCode   643638 non-null  object
 1   SeriesCode    643638 non-null  object
 2   Year          643638 non-null  object
 3   DESCRIPTION   643638 non-null  object
 4   Unnamed: 4    0 non-null       float64
dtypes: float64(1), object(4)
memory usage: 24.6+ MB
```

Observations: 643638 lignes, 5 colonnes, EdStatsFootNote.csv contient des notes, dates ou description de mise à jour, sur certains indicateurs par pays et par années.

Vérification du fichier EdStatsData.csv

In [12]:
```
data = pd.read_csv('EdStatsData.csv')
```

In [13]:
```
data.head(3)
```

Out[13]:

	Country Name	Country Code	Indicator Name	Indicator Code	1970	1971	1972	1973	1974	1975	...	2060	2065	2070	2
0	Arab World	ARB	Adjusted net enrolment rate, lower secondary, ...	UIS.NERA.2	NaN	NaN	NaN	NaN	NaN	NaN	...	NaN	NaN	NaN	N
1	Arab World	ARB	Adjusted net enrolment rate, lower secondary, ...	UIS.NERA.2.F	NaN	NaN	NaN	NaN	NaN	NaN	...	NaN	NaN	NaN	N
2	Arab World	ARB	Adjusted net enrolment rate, lower secondary, ...	UIS.NERA.2.GPI	NaN	NaN	NaN	NaN	NaN	NaN	...	NaN	NaN	NaN	N

3 rows × 70 columns

In [14]:
```
data.tail(3)
```

Out[14]:

	Country	Country	Indicator	Indicator Code	1970	1971	1972	1973	1974	1975	...	2060	2

	Name	Code	Name										
886927	Zimbabwe	ZWE	Youth literacy rate, population 15-24 years, f...	SE.ADT.1524.LT.FE.ZS	NaN	NaN	NaN	NaN	NaN	NaN	...	NaN	N
886928	Zimbabwe	ZWE	Youth literacy rate, population 15-24 years, g...	SE.ADT.1524.LT.FM.ZS	NaN	NaN	NaN	NaN	NaN	NaN	...	NaN	N
886929	Zimbabwe	ZWE	Youth literacy rate, population 15-24 years, m...	SE.ADT.1524.LT.MA.ZS	NaN	NaN	NaN	NaN	NaN	NaN	...	NaN	N

3 rows × 70 columns

In [15]:
```
data.isna().sum(axis=0)  # identifier les valeurs manquantes
```

Out[15]:
```
Country Name           0
Country Code           0
Indicator Name         0
Indicator Code         0
1970              814642
                   ...
2085              835494
2090              835494
2095              835494
2100              835494
Unnamed: 69       886930
Length: 70, dtype: int64
```

In [16]:
```
data.info()
```

```
<class 'pandas.core.frame.DataFrame'>
RangeIndex: 886930 entries, 0 to 886929
Data columns (total 70 columns):
 #   Column          Non-Null Count   Dtype
---  ------          --------------   -----
 0   Country Name    886930 non-null  object
 1   Country Code    886930 non-null  object
 2   Indicator Name  886930 non-null  object
 3   Indicator Code  886930 non-null  object
 4   1970            72288 non-null   float64
 5   1971            35537 non-null   float64
 6   1972            35619 non-null   float64
 7   1973            35545 non-null   float64
 8   1974            35730 non-null   float64
 9   1975            87306 non-null   float64
 10  1976            37483 non-null   float64
 11  1977            37574 non-null   float64
 12  1978            37576 non-null   float64
 13  1979            36809 non-null   float64
 14  1980            89122 non-null   float64
 15  1981            38777 non-null   float64
 16  1982            37511 non-null   float64
 17  1983            38460 non-null   float64
```

```
 18  1984            38606 non-null   float64
 19  1985            90296 non-null   float64
 20  1986            39372 non-null   float64
 21  1987            38641 non-null   float64
 22  1988            38552 non-null   float64
 23  1989            37540 non-null   float64
 24  1990            124405 non-null  float64
 25  1991            74437 non-null   float64
 26  1992            75543 non-null   float64
 27  1993            75793 non-null   float64
 28  1994            77462 non-null   float64
 29  1995            131361 non-null  float64
 30  1996            76807 non-null   float64
 31  1997            73453 non-null   float64
 32  1998            84914 non-null   float64
 33  1999            118839 non-null  float64
 34  2000            176676 non-null  float64
 35  2001            123509 non-null  float64
 36  2002            124205 non-null  float64
 37  2003            130363 non-null  float64
 38  2004            128814 non-null  float64
 39  2005            184108 non-null  float64
 40  2006            140312 non-null  float64
 41  2007            137272 non-null  float64
 42  2008            134387 non-null  float64
 43  2009            142108 non-null  float64
 44  2010            242442 non-null  float64
 45  2011            146012 non-null  float64
 46  2012            147264 non-null  float64
 47  2013            137509 non-null  float64
 48  2014            113789 non-null  float64
 49  2015            131058 non-null  float64
 50  2016            16460 non-null   float64
 51  2017            143 non-null     float64
 52  2020            51436 non-null   float64
 53  2025            51436 non-null   float64
 54  2030            51436 non-null   float64
 55  2035            51436 non-null   float64
 56  2040            51436 non-null   float64
 57  2045            51436 non-null   float64
 58  2050            51436 non-null   float64
 59  2055            51436 non-null   float64
 60  2060            51436 non-null   float64
 61  2065            51436 non-null   float64
 62  2070            51436 non-null   float64
 63  2075            51436 non-null   float64
 64  2080            51436 non-null   float64
 65  2085            51436 non-null   float64
 66  2090            51436 non-null   float64
 67  2095            51436 non-null   float64
 68  2100            51436 non-null   float64
 69  Unnamed: 69     0 non-null       float64
dtypes: float64(66), object(4)
memory usage: 473.7+ MB
```

In [17]:
```
data.shape #pour obtenir les dimensions
```

Out[17]:
```
(886930, 70)
```

In [18]:
```
data.dtypes #pour obtenir les types de données de chaque colonne
```

Out[18]:
```
Country Name       object
Country Code       object
Indicator Name     object
Indicator Code     object
```

```
1970              float64
                   ...
2085              float64
2090              float64
2095              float64
2100              float64
Unnamed: 69       float64
Length: 70, dtype: object
```

In [19]:
```
data['Indicator Name'].unique() # pour obtenir les valeurs uniques de la colonne "Indica
```

Out[19]:
```
array(['Adjusted net enrolment rate, lower secondary, both sexes (%)',
       'Adjusted net enrolment rate, lower secondary, female (%)',
       'Adjusted net enrolment rate, lower secondary, gender parity index (GPI)',
       ..., 'Youth literacy rate, population 15-24 years, female (%)',
       'Youth literacy rate, population 15-24 years, gender parity index (GPI)',
       'Youth literacy rate, population 15-24 years, male (%)'],
      dtype=object)
```

In [20]:
```
print("{}  indicateurs".format(data['Indicator Name'].nunique()))
```

```
3665  indicateurs
```

In [21]:
```
data.groupby('Country Name')['Indicator Code'].count()
print("{} indicateurs par pays".format(data.groupby('Country Name')['Indicator Code'].co
```

```
3665 indicateurs par pays
```

Observation: 886 930 lignes, 70 colonnes, ce fichier contient les données relatives aux 3665 indicateurs, mesurées par pays et faux pays(groupement de pays, de revenus...), depuis 1970, ainsi que des projections jusqu'à 2100 . Le densité des données est uniforme à partir de 2020 (51436 valeurs non-nulles par années). Il n'y a aucune donnée en 2018 et 2019, la quantité de données pour 2017 et 2016 est très faible comparées aux autres années. Avant 2016, la quantité de données est très hétérogène.Elle est beaucoup plus elevée entre 1990 et 2015 comparativement à la période 2020-2100. Nous remarquons un accroissement de données à chaque début de décennie.

Une analyse plus approfondie de ce jeu de donnée via le site de la Worldbank (https://datacatalog.worldbank.org/dataset/education-statistics http://datatopics.worldbank.org/education/), le moteur de recherche Google et l'utilisation de Dataprep (bibliothèque Python open-source) pour automatiser l'analyse exploratoire des données, nous ont conduit à nous concentrer, uniquement, sur le fichier le plus important EdStatsData.csv.

3. Séquence de Filtrage des données.

Supression des faux pays

In [22]:
```
#Afghanistan est le premier pays de la liste des pays classés alphabétiquement
# Sélectionner les lignes dans data où 'Country Name' est égal à 'Afghanistan'
separation_1 = data[data['Country Name'].isin(['Afghanistan'])]
#séparation_1
```

In [23]:
```
#séparation_1= data[data['Country Name'] == 'Afghanistan']
#séparation_1
```

In [24]:
```
#conserver les pays
#Sélectionner les lignes à partir de l'index 91625 de  data
data_pays_select= data.loc[91625:,:]
```

```
#Afficher les dimensions de la DataFrame data_pays_select
data_pays_select.shape
```

Out[24]:

```
(795305, 70)
```

In [25]:

```
data_pays_select.describe() #afficher les statistiques descriptives
```

Out[25]:

	1970	1971	1972	1973	1974	1975	1976
count	6.858100e+04	3.171300e+04	3.162900e+04	3.143200e+04	3.158600e+04	8.307700e+04	3.321100e+04
mean	3.307705e+08	7.572854e+08	8.218597e+08	9.161492e+08	9.663843e+08	3.839944e+08	1.023072e+09
std	2.289666e+10	3.501398e+10	3.718576e+10	3.987381e+10	4.019633e+10	2.513404e+10	4.208708e+10
min	-1.435564e+00	-1.594625e+00	-3.056522e+00	-4.032582e+00	-4.213563e+00	-3.658569e+00	-2.950945e+00
25%	8.000000e-01	8.170800e+00	8.605000e+00	8.975150e+00	9.224063e+00	1.300000e+00	8.604725e+00
50%	5.700000e+00	5.613826e+01	6.075474e+01	6.440604e+01	6.551884e+01	8.540000e+00	6.604468e+01
75%	5.304000e+01	3.239300e+04	3.434700e+04	3.675200e+04	3.828750e+04	6.892000e+01	3.295000e+04
max	4.779684e+12	4.937198e+12	5.197055e+12	5.490332e+12	5.461938e+12	5.451141e+12	5.744745e+12

8 rows × 66 columns

In [26]:

```
#World est le dernier faux pays de la liste des faux pays classés alphabétiquement
# Sélectionner les lignes de  data où 'Country Name' est égal à 'World'
séparation_2= data[data['Country Name'].isin(['World'])]
séparation_2
```

Out[26]:

	Country Name	Country Code	Indicator Name	Indicator Code	1970	1971	1972	1973	1974
87960	World	WLD	Adjusted net enrolment rate, lower secondary, ...	UIS.NERA.2	NaN	NaN	NaN	NaN	NaN
87961	World	WLD	Adjusted net enrolment rate, lower secondary, ...	UIS.NERA.2.F	NaN	NaN	NaN	NaN	NaN
87962	World	WLD	Adjusted net enrolment rate, lower secondary, ...	UIS.NERA.2.GPI	NaN	NaN	NaN	NaN	NaN
87963	World	WLD	Adjusted net enrolment rate, lower secondary, ...	UIS.NERA.2.M	NaN	NaN	NaN	NaN	NaN
87964	World	WLD	Adjusted net enrolment	SE.PRM.TENR	72.353142	72.258461	73.130409	75.258324	75.926712

			rate, primary, both sex...						
...	...	...	...	...	...	...	...	...	...
91620	World	WLD	Youth illiterate population, 15-24 years, male...	UIS.LP.AG15T24.M	NaN	NaN	NaN	NaN	NaN
91621	World	WLD	Youth literacy rate, population 15-24 years, b...	SE.ADT.1524.LT.ZS	NaN	NaN	NaN	NaN	NaN
91622	World	WLD	Youth literacy rate, population 15-24 years, f...	SE.ADT.1524.LT.FE.ZS	NaN	NaN	NaN	NaN	NaN
91623	World	WLD	Youth literacy rate, population 15-24 years, g...	SE.ADT.1524.LT.FM.ZS	NaN	NaN	NaN	NaN	NaN
91624	World	WLD	Youth literacy rate, population 15-24 years, m...	SE.ADT.1524.LT.MA.ZS	NaN	NaN	NaN	NaN	NaN

3665 rows × 70 columns

In [27]:
```
#On crée le dataframe contenant les données par faux pays
#Sélectionner les lignes jusqu'à l'index 91624 de  data
data_faux_pays_select = data.loc[:91624,:]
data_faux_pays_select.shape
```

Out[27]:
```
(91625, 70)
```

Choix de la période avec les données les plus pertinantes

In [28]:
```
#choix de la période avec les données les plus pertinantes
import matplotlib.pyplot as plt
import seaborn as sns
%matplotlib inline
sns.set(style="darkgrid")
plt.figure(figsize=(26,8))
plt.title('Données significatives par année',size=16)
# Compter le nombre de valeurs  manquantes pour chaque année
non_missing_counts = data_pays_select.shape[0] - data_pays_select[[str(annee) for annee

# Afficher un graphique en barres indiquant le nombre de données significatives par anné
sns.barplot(x=non_missing_counts.index, y=non_missing_counts.values)
```

```
plt.show()
```

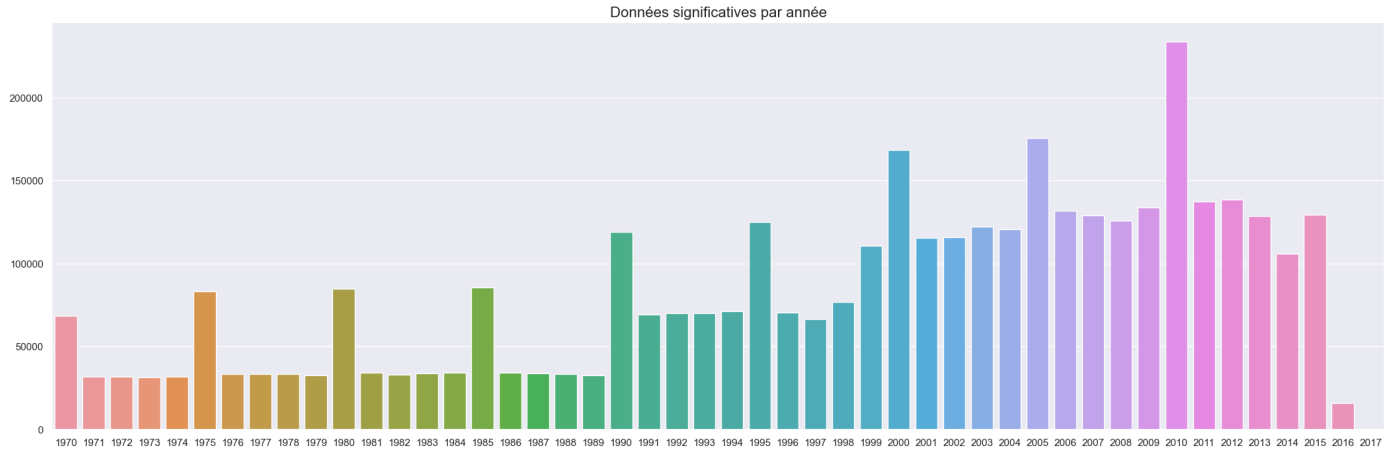

nous remarquons que sur la période 2005->2015 la quantité des données est la plus important. Nous prendrons la valeur moyenne de la période 2005-2015 comme référence pour notre étude

In [29]:

```
import warnings
warnings.filterwarnings('ignore')
# Créer des colonnes pour chaque décennie
# Ajouter une colonne pour chaque décennie représentant la moyenne des valeurs pour cett
data_pays_select['1970s']=data_pays_select[[str(annee) for annee in range(1970,1980,1)]]
data_pays_select['1980s'] = data_pays_select[[str(annee) for annee in range(1980,1990,1)
data_pays_select['1990s'] = data[[str(annee) for annee in range(1990,2000,1)]].mean(1)
data_pays_select['2000s'] = data_pays_select[[str(annee) for annee in range(2000,2010,1)
data_pays_select['2005-2015'] = data_pays_select[[str(annee) for annee in range(2005,201
data_pays_select['2020s'] = data_pays_select[[str(annee) for annee in [2020,2025]]].mean
data_pays_select['2030s'] = data_pays_select[[str(annee) for annee in [2030,2035]]].mean
data_pays_select['2040s'] = data_pays_select[[str(annee) for annee in [2040,2045]]].mean
data_pays_select['2050s'] = data_pays_select[[str(annee) for annee in [2050,2055]]].mean
data_pays_select['2060s'] = data_pays_select[[str(annee) for annee in [2060,2065]]].mean
data_pays_select['2070s'] = data_pays_select[[str(annee) for annee in [2070,2075]]].mean
data_pays_select['2080s'] = data_pays_select[[str(annee) for annee in [2080,2085]]].mean
data_pays_select['2090s'] = data_pays_select[[str(annee) for annee in [2090,2095]]].mean
data_pays_select['2100s'] = data_pays_select[[str(2100)]].mean(1)
data_pays_select.head(5)
```

Out[29]:

	Country Name	Country Code	Indicator Name	Indicator Code	1970	1971	1972	1973	1974	1975	...	2005-2015
91625	Afghanistan	AFG	Adjusted net enrolment rate, lower secondary, ...	UIS.NERA.2	NaN	NaN	NaN	NaN	7.05911	NaN	...	42.041297
91626	Afghanistan	AFG	Adjusted net enrolment rate, lower secondary, ...	UIS.NERA.2.F	NaN	NaN	NaN	NaN	2.53138	NaN	...	28.979300
91627	Afghanistan	AFG	Adjusted net enrolment rate, lower secondary, ...	UIS.NERA.2.GPI	NaN	NaN	NaN	NaN	0.22154	NaN	...	0.514853

91628	Afghanistan	AFG	Adjusted net enrolment rate, lower secondary, ...	UIS.NERA.2.M	NaN	NaN	NaN	NaN	11.42652	NaN	...	54.382287
91629	Afghanistan	AFG	Adjusted net enrolment rate, primary, both sex...	SE.PRM.TENR	NaN	NaN	NaN	NaN	NaN	NaN	...	NaN

5 rows × 84 columns

Données par decennie qui confirme notre choix

In [30]:
```
## afficher les donnée par decennie qui confirme notre choix
#créer une liste de noms de colonnes qui représentent différentes décennies
decade_columns=['1970s', '1980s','1990s', '2000s', '2005-2015', '2020s', '2030s', '2040s
'2050s', '2060s', '2070s', '2080s', '2090s', '2100s']
sns.set(style="darkgrid")
plt.figure(figsize=(20,4))
plt.title('Données par décennie',size=16)
plot=sns.barplot(y=data_pays_select.shape[0]-data_pays_select[decade_columns].isna().sum
plt.show()
```

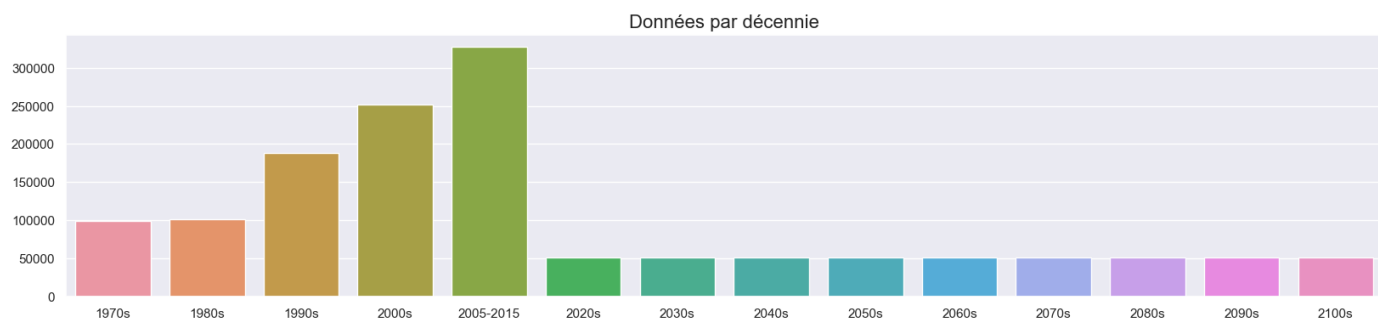

In [31]:
```
data_pays_select.info()
```

```
<class 'pandas.core.frame.DataFrame'>
RangeIndex: 795305 entries, 91625 to 886929
Data columns (total 84 columns):
 #   Column          Non-Null Count   Dtype
---  ------          --------------   -----
 0   Country Name    795305 non-null  object
 1   Country Code    795305 non-null  object
 2   Indicator Name  795305 non-null  object
 3   Indicator Code  795305 non-null  object
 4   1970            68581 non-null   float64
 5   1971            31713 non-null   float64
 6   1972            31629 non-null   float64
 7   1973            31432 non-null   float64
 8   1974            31586 non-null   float64
 9   1975            83077 non-null   float64
 10  1976            33211 non-null   float64
 11  1977            33283 non-null   float64
 12  1978            33279 non-null   float64
 13  1979            32470 non-null   float64
 14  1980            84684 non-null   float64
 15  1981            34314 non-null   float64
 16  1982            33044 non-null   float64
```

```
17  1983            33913 non-null   float64
18  1984            34019 non-null   float64
19  1985            85403 non-null   float64
20  1986            34353 non-null   float64
21  1987            33617 non-null   float64
22  1988            33512 non-null   float64
23  1989            32484 non-null   float64
24  1990            119085 non-null  float64
25  1991            69036 non-null   float64
26  1992            69879 non-null   float64
27  1993            69956 non-null   float64
28  1994            71306 non-null   float64
29  1995            125112 non-null  float64
30  1996            70537 non-null   float64
31  1997            66445 non-null   float64
32  1998            76850 non-null   float64
33  1999            110634 non-null  float64
34  2000            168404 non-null  float64
35  2001            115195 non-null  float64
36  2002            115859 non-null  float64
37  2003            122013 non-null  float64
38  2004            120445 non-null  float64
39  2005            175671 non-null  float64
40  2006            131865 non-null  float64
41  2007            128801 non-null  float64
42  2008            125883 non-null  float64
43  2009            133556 non-null  float64
44  2010            233590 non-null  float64
45  2011            137436 non-null  float64
46  2012            138440 non-null  float64
47  2013            128688 non-null  float64
48  2014            105644 non-null  float64
49  2015            129271 non-null  float64
50  2016            15720 non-null   float64
51  2017            143 non-null     float64
52  2020            51128 non-null   float64
53  2025            51128 non-null   float64
54  2030            51128 non-null   float64
55  2035            51128 non-null   float64
56  2040            51128 non-null   float64
57  2045            51128 non-null   float64
58  2050            51128 non-null   float64
59  2055            51128 non-null   float64
60  2060            51128 non-null   float64
61  2065            51128 non-null   float64
62  2070            51128 non-null   float64
63  2075            51128 non-null   float64
64  2080            51128 non-null   float64
65  2085            51128 non-null   float64
66  2090            51128 non-null   float64
67  2095            51128 non-null   float64
68  2100            51128 non-null   float64
69  Unnamed: 69     0 non-null       float64
70  1970s           98631 non-null   float64
71  1980s           101761 non-null  float64
72  1990s           188368 non-null  float64
73  2000s           252209 non-null  float64
74  2005-2015       327084 non-null  float64
75  2020s           51128 non-null   float64
76  2030s           51128 non-null   float64
77  2040s           51128 non-null   float64
78  2050s           51128 non-null   float64
79  2060s           51128 non-null   float64
80  2070s           51128 non-null   float64
81  2080s           51128 non-null   float64
82  2090s           51128 non-null   float64
```

```
 83  2100s           51128 non-null   float64
dtypes: float64(80), object(4)
memory usage: 509.7+ MB
```

In [32]:

```python
# sélectionner les colonnes à conserver
cols_to_keep = [ 'Country Name','Country Code','Indicator Name','Indicator Code','2005-2
# créer un masque de booléens indiquant si chaque colonne est à conserver ou non
mask = data_pays_select.columns.isin(cols_to_keep)
# garder uniquement les colonnes sélectionnées
data_pays_select= data_pays_select.loc[:, mask]
data_pays_select
```

Out[32]:

	Country Name	Country Code	Indicator Name	Indicator Code	2005-2015
91625	Afghanistan	AFG	Adjusted net enrolment rate, lower secondary, ...	UIS.NERA.2	42.041297
91626	Afghanistan	AFG	Adjusted net enrolment rate, lower secondary, ...	UIS.NERA.2.F	28.979300
91627	Afghanistan	AFG	Adjusted net enrolment rate, lower secondary, ...	UIS.NERA.2.GPI	0.514853
91628	Afghanistan	AFG	Adjusted net enrolment rate, lower secondary, ...	UIS.NERA.2.M	54.382287
91629	Afghanistan	AFG	Adjusted net enrolment rate, primary, both sex...	SE.PRM.TENR	NaN
...	...	...	...	...	...
886925	Zimbabwe	ZWE	Youth illiterate population, 15-24 years, male...	UIS.LP.AG15T24.M	183071.500000
886926	Zimbabwe	ZWE	Youth literacy rate, population 15-24 years, b...	SE.ADT.1524.LT.ZS	90.679410
886927	Zimbabwe	ZWE	Youth literacy rate, population 15-24 years, f...	SE.ADT.1524.LT.FE.ZS	92.656455
886928	Zimbabwe	ZWE	Youth literacy rate, population 15-24 years, g...	SE.ADT.1524.LT.FM.ZS	1.046085
886929	Zimbabwe	ZWE	Youth literacy rate, population 15-24 years, m...	SE.ADT.1524.LT.MA.ZS	88.591220

795305 rows × 5 columns

Indicateurs adéquats pour notre problematique

In [33]:

```python
#filtrer les indicateurs adéquats pour notre problematique
indic_adhoc = ['IT.NET.USER.P2','NY.GDP.PCAP.PP.CD','SP.POP.1524.TO.UN','SE.TER.ENRL']

data_pays_select= data_pays_select[data_pays_select['Indicator Code'].isin(indic_adhoc)]
data_pays_select.head(9)
```

Out[33]:

	Country Name	Country Code	Indicator Name	Indicator Code	2005-2015
92829	Afghanistan	AFG	Enrolment in tertiary education, all programme...	SE.TER.ENRL	1.518543e+05
92872	Afghanistan	AFG	GDP per capita, PPP (current international $)	NY.GDP.PCAP.PP.CD	1.488521e+03

93000	Afghanistan	AFG	Internet users (per 100 people)	IT.NET.USER.P2	3.797582e+00
94107	Afghanistan	AFG	Population, ages 15-24, total	SP.POP.1524.TO.UN	5.969358e+06
96494	Albania	ALB	Enrolment in tertiary education, all programme...	SE.TER.ENRL	1.173502e+05
96537	Albania	ALB	GDP per capita, PPP (current international $)	NY.GDP.PCAP.PP.CD	8.921302e+03
96665	Albania	ALB	Internet users (per 100 people)	IT.NET.USER.P2	3.617060e+01
97772	Albania	ALB	Population, ages 15-24, total	SP.POP.1524.TO.UN	5.958177e+05
100159	Algeria	DZA	Enrolment in tertiary education, all programme...	SE.TER.ENRL	1.078053e+06

In [34]:
```
data_pays_select.info()
```

```
<class 'pandas.core.frame.DataFrame'>
Int64Index: 868 entries, 92829 to 885747
Data columns (total 5 columns):
 #   Column          Non-Null Count  Dtype
---  ------          --------------  -----
 0   Country Name    868 non-null    object
 1   Country Code    868 non-null    object
 2   Indicator Name  868 non-null    object
 3   Indicator Code  868 non-null    object
 4   2005-2015       769 non-null    float64
dtypes: float64(1), object(4)
memory usage: 40.7+ KB
```

In [35]:
```
warnings.filterwarnings('ignore')
#supprimer des colonnes
data_pays_select.drop(['Country Code', 'Indicator Code'], axis=1, inplace=True)
data_pays_select.head(9)
```

Out[35]:

	Country Name	Indicator Name	2005-2015
92829	Afghanistan	Enrolment in tertiary education, all programme...	1.518543e+05
92872	Afghanistan	GDP per capita, PPP (current international $)	1.488521e+03
93000	Afghanistan	Internet users (per 100 people)	3.797582e+00
94107	Afghanistan	Population, ages 15-24, total	5.969358e+06
96494	Albania	Enrolment in tertiary education, all programme...	1.173502e+05
96537	Albania	GDP per capita, PPP (current international $)	8.921302e+03
96665	Albania	Internet users (per 100 people)	3.617060e+01
97772	Albania	Population, ages 15-24, total	5.958177e+05
100159	Algeria	Enrolment in tertiary education, all programme...	1.078053e+06

Pivot: les 4 valeurs de 'Indicator Name' deviennent des colonnes

In [36]:
```
#Les 4 valeurs de 'Indicator Name' deviennent des colonnes :

data_pays_select = data_pays_select.pivot_table(index= ["Country Name"],
                                                columns= ["Indicator Name"],
                                                values= ["2005-2015"])
```

```
data_pays_select = data_pays_select.reset_index()
data_pays_select.head(70)
```

Out[36]:

Indicator Name	Country Name	Enrolment in tertiary education, all programmes, both sexes (number)	GDP per capita, PPP (current international $)	Internet users (per 100 people)	2005-2015 Population, ages 15-24, total
0	Afghanistan	1.518543e+05	1488.521343	3.797582	5969357.5
1	Albania	1.173502e+05	8921.302486	36.170596	595817.7
2	Algeria	1.078053e+06	12547.683912	14.168112	7177105.6
3	American Samoa	1.607000e+03	NaN	NaN	NaN
4	Andorra	4.548333e+02	NaN	74.431704	8589.5
...	...	...	...	...	...
65	Finland	3.066367e+05	38482.395465	84.460479	653210.9
66	France	2.243335e+06	35805.976357	70.029980	7663754.7
67	French Polynesia	NaN	NaN	42.206678	NaN
68	Gabon	NaN	15596.307123	15.675871	288542.2
69	Gambia, The	4.557000e+03	1518.739741	9.183126	344717.3

70 rows × 5 columns

Renommage des colonnes

In [37]:

```
# Renommer des colonnes

data_pays_select.columns = ['Pays','Inscription', 'PIB', 'NET.USER', 'Pop.Tot1524']

data_pays_select.set_index('Pays')
data_pays_select['Inscription'] = data_pays_select['Inscription'].fillna(1622693)
data_pays_select.head(70)
```

Out[37]:

	Pays	Inscription	PIB	NET.USER	Pop.Tot1524
0	Afghanistan	1.518543e+05	1488.521343	3.797582	5969357.5
1	Albania	1.173502e+05	8921.302486	36.170596	595817.7
2	Algeria	1.078053e+06	12547.683912	14.168112	7177105.6
3	American Samoa	1.607000e+03	NaN	NaN	NaN
4	Andorra	4.548333e+02	NaN	74.431704	8589.5
...	...	...	...	...	...
65	Finland	3.066367e+05	38482.395465	84.460479	653210.9
66	France	2.243335e+06	35805.976357	70.029980	7663754.7
67	French Polynesia	1.622693e+06	NaN	42.206678	NaN
68	Gabon	1.622693e+06	15596.307123	15.675871	288542.2

69	Gambia, The	4.557000e+03	1518.739741	9.183126	344717.3

70 rows × 5 columns

In [38]:
```
data_pays_select.describe()
```

Out[38]:

	Inscription	PIB	NET.USER	Pop.Tot1524
count	2.120000e+02	192.000000	204.000000	1.910000e+02
mean	1.050794e+06	17351.613693	32.856732	6.277149e+06
std	2.942541e+06	19858.710157	26.091617	2.364337e+07
min	3.500000e+00	604.662387	0.000000	2.778500e+03
25%	3.701014e+04	3281.922716	9.003418	3.132007e+05
50%	2.311611e+05	9803.946912	28.286995	1.232513e+06
75%	1.622693e+06	23245.709268	52.418095	4.494809e+06
max	2.962521e+07	118067.967253	93.023629	2.324822e+08

In [39]:
```
import missingno as msno
#visualiser les données manquantes
msno.bar(data_pays_select)
```

Out[39]:
```
<AxesSubplot:>
```

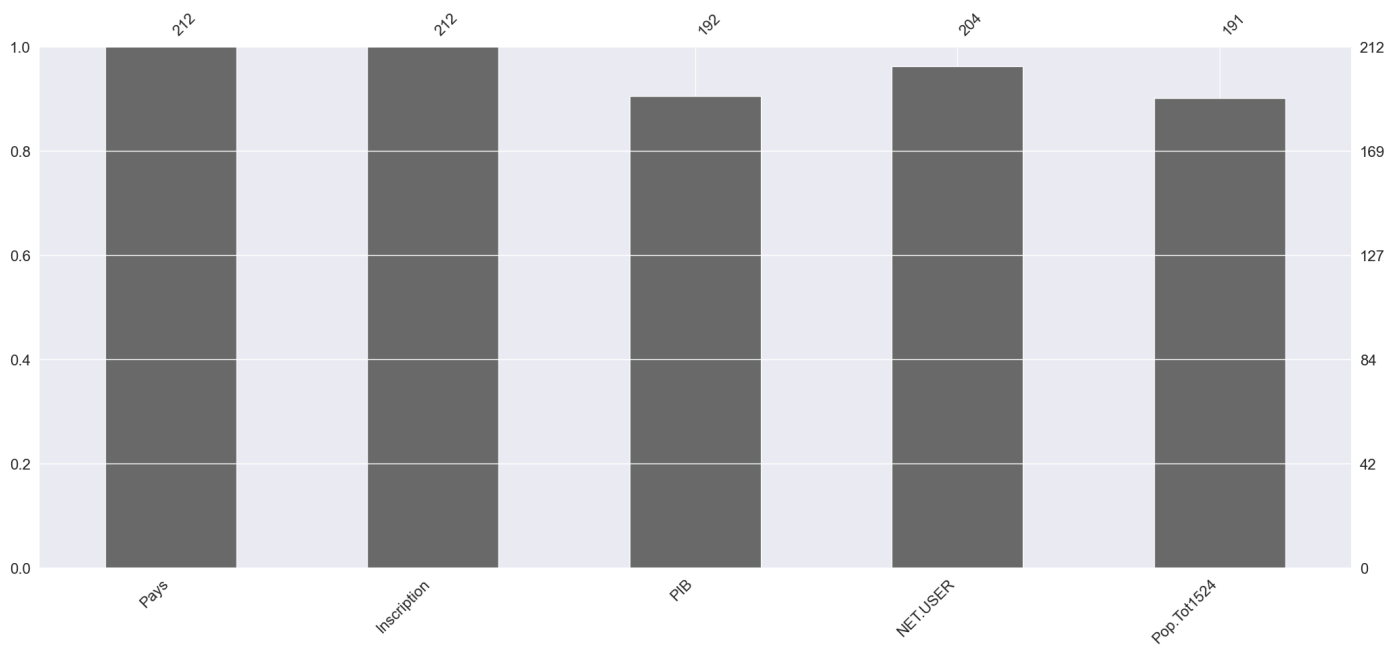

In [40]:
```
data_pays_select.info
```

Out[40]:
```
<bound method DataFrame.info of                        Pays   Inscription           PIB
NET.USER  Pop.Tot1524
0               Afghanistan  1.518543e+05   1488.521343   3.797582    5969357.5
1                   Albania  1.173502e+05   8921.302486  36.170596     595817.7
2                   Algeria  1.078053e+06  12547.683912  14.168112    7177105.6
3            American Samoa  1.607000e+03           NaN        NaN          NaN
4                   Andorra  4.548333e+02           NaN  74.431704       8589.5
..                      ...           ...           ...        ...          ...
207  Virgin Islands (U.S.)  2.488000e+03           NaN  33.951245          NaN
208     West Bank and Gaza  1.876362e+05           NaN  33.432900     866404.2
209            Yemen, Rep.  2.433257e+05   3970.633769  11.140792    5255140.2
210                 Zambia  5.621950e+04   3059.944302   9.310987    2697762.4
```

```
211                Zimbabwe  9.400575e+04   1585.039473   7.396474     3355468.1

[212 rows x 5 columns]>
```

Selections des pays

In [41]:
```
#Sélectionner les lignes où la valeur de PIB est supérieure ou égale à 32873 (80% PIB de
#et la valeur de Pop.Tot1524 est supérieure ou égale à 500000 dans le DataFrame data_pay

df_seuil_PIB_POP = data_pays_select.loc [((data_pays_select['PIB'] >=  32873) & (data_pa
```

In [42]:
```
df_seuil_PIB_POP.info()
```

```
<class 'pandas.core.frame.DataFrame'>
Int64Index: 22 entries, 10 to 201
Data columns (total 5 columns):
 #   Column       Non-Null Count  Dtype
---  ------       --------------  -----
 0   Pays         22 non-null     object
 1   Inscription  22 non-null     float64
 2   PIB          22 non-null     float64
 3   NET.USER     22 non-null     float64
 4   Pop.Tot1524  22 non-null     float64
dtypes: float64(4), object(1)
memory usage: 1.0+ KB
```

22 pays en liste

In [43]:
```
df_seuil_PIB_POP.head(30)
```

Out[43]:

	Pays	Inscription	PIB	NET.USER	Pop.Tot1524
10	Australia	1.227505e+06	39703.799055	74.631119	2891825.9
11	Austria	3.283950e+05	42424.715781	73.284461	1001962.0
18	Belgium	4.374370e+05	39376.870780	72.048019	1259041.1
35	Canada	1.622693e+06	40557.236537	79.348000	4443212.6
52	Denmark	2.525646e+05	41899.681838	88.768973	657582.6
65	Finland	3.066367e+05	38482.395465	84.460479	653210.9
66	France	2.243335e+06	35805.976357	70.029980	7663754.7
71	Germany	2.846108e+06	39572.319563	78.901000	9393699.1
84	Hong Kong SAR, China	2.419134e+05	46587.654773	68.976627	887453.6
91	Ireland	1.910398e+05	45234.143948	66.990599	606023.7
93	Italy	1.970418e+06	34642.310665	48.513776	5821794.0
95	Japan	3.929535e+06	35347.160776	77.739311	12921826.9
136	Netherlands	6.475139e+05	44632.015920	88.819305	1987072.4
142	Norway	2.288138e+05	59352.288863	90.700336	615806.9
143	Oman	7.729478e+04	41996.265428	35.896110	564948.8
161	Saudi Arabia	9.371469e+05	46023.909937	40.387825	4853746.7
166	Singapore	2.219153e+05	69369.411362	70.183129	634866.4
182	Sweden	4.330436e+05	41574.366613	89.885357	1186952.4

183	Switzerland	2.421074e+05	52894.263980	81.153303	940874.6
199	United Arab Emirates	1.087372e+05	67426.982168	68.939999	691985.5
200	United Kingdom	2.393757e+06	36368.964439	81.517410	7955471.5
201	United States	1.919801e+07	49120.975228	71.741871	44573903.0

4. Normalisation

In [44]:
```
from sklearn import preprocessing
```

In [45]:
```
#Cette fonction  effectue la normalisation sur les colonnes sélectionnées
def normalize_data(df):
    # Sélectionne les colonnes de l'index 1 à 5 à l'aide de la fonction .iloc[]
    df_ind = df.iloc[:, 1:5]
    # Arrondit les valeurs de ces colonnes à une décimale
    df_ind=df_ind.round(1)
    # Crée une instance de la classe MinMaxScaler de la bibliothèque sklearn preprocessi
    min_max_scaler = preprocessing.MinMaxScaler(feature_range =(0, 1))
    # Appelle la méthode fit_transform sur l'instance MinMaxScaler pour normaliser les d
    df_ind_apres_min_max_scaler = min_max_scaler.fit_transform(df_ind)
    # Les données normalisées obtenues sont à nouveau arrondies à une décimale
    df_ind_apres_min_max_scaler=df_ind_apres_min_max_scaler.round(1)
    # Retourne finalement les données normalisées
    return df_ind_apres_min_max_scaler

df_ind_apres_min_max_scaler = normalize_data(df_seuil_PIB_POP)
df_ind_apres_min_max_scaler
```

Out[45]:
```
array([[0.1, 0.1, 0.7, 0.1],
       [0. , 0.2, 0.7, 0. ],
       [0. , 0.1, 0.7, 0. ],
       [0.1, 0.2, 0.8, 0.1],
       [0. , 0.2, 1. , 0. ],
       [0. , 0.1, 0.9, 0. ],
       [0.1, 0. , 0.6, 0.2],
       [0.1, 0.1, 0.8, 0.2],
       [0. , 0.3, 0.6, 0. ],
       [0. , 0.3, 0.6, 0. ],
       [0.1, 0. , 0.2, 0.1],
       [0.2, 0. , 0.8, 0.3],
       [0. , 0.3, 1. , 0. ],
       [0. , 0.7, 1. , 0. ],
       [0. , 0.2, 0. , 0. ],
       [0. , 0.3, 0.1, 0.1],
       [0. , 1. , 0.6, 0. ],
       [0. , 0.2, 1. , 0. ],
       [0. , 0.5, 0.8, 0. ],
       [0. , 0.9, 0.6, 0. ],
       [0.1, 0. , 0.8, 0.2],
       [1. , 0.4, 0.7, 1. ]])
```

5.Méthode de classement des pays

Etape 1

In [46]:
```
#Trier les données par ordre décroissant pour les colonnes "Inscription","PIB","NET.USER
Inscription = df_seuil_PIB_POP.sort_values(by = 'Inscription', ascending=False)
PIB = df_seuil_PIB_POP.sort_values(by = 'PIB', ascending=False)
NET_USER = df_seuil_PIB_POP.sort_values(by = 'NET.USER', ascending=False)
```

```
Pop_Tot1524 = df_seuil_PIB_POP.sort_values(by = 'Pop.Tot1524', ascending=False)

#Récupérer les 10 premiers pays uniques pour les colonnes "Inscription","PIB","NET.USER"

list_Inscription = Inscription.head(10)['Pays'].unique()
list_PIB = PIB.head(10)['Pays'].unique()
list_NET_USER= NET_USER.head(10)['Pays'].unique()
list_Pop_Tot1524 = Pop_Tot1524.head(10)['Pays'].unique()


#Créer une liste de tuples comprenant les données et les poids pour chaque indicateur
listes = [  ("Inscription", list_Inscription, "poids_Inscription"),  ("PIB", list_PIB, "
listes
```

Out[46]:

```
[('Inscription',
  array(['United States', 'Japan', 'Germany', 'United Kingdom', 'France',
         'Italy', 'Canada', 'Australia', 'Saudi Arabia', 'Netherlands'],
        dtype=object),
  'poids_Inscription'),
 ('PIB',
  array(['Singapore', 'United Arab Emirates', 'Norway', 'Switzerland',
         'United States', 'Hong Kong SAR, China', 'Saudi Arabia', 'Ireland',
         'Netherlands', 'Austria'], dtype=object),
  'poids_PIB'),
 ('NET.USER',
  array(['Norway', 'Sweden', 'Netherlands', 'Denmark', 'Finland',
         'United Kingdom', 'Switzerland', 'Canada', 'Germany', 'Japan'],
        dtype=object),
  'poids_NET_USER'),
 ('Pop.Tot1524',
  array(['United States', 'Japan', 'Germany', 'United Kingdom', 'France',
         'Italy', 'Saudi Arabia', 'Canada', 'Australia', 'Netherlands'],
        dtype=object),
  'PoidsPop_Tot1524')]
```

Mais quels pays choisir parmi ces listes de pays?

Etape 2

In [47]:

```
#Initialiser une liste vide
dfs = []

#iterer
for nom_ind, données, nom_poids in listes:
#Créer une liste de poids allant de la longueur de "données" à 0, décrémentant de 1 à ch
    poids = list(range(len(données), 0, -1))
#Combiner les éléments de "données" et "poids" en paires
    zipped = list(zip(données, poids))
#Créer un DataFrame pandas à partir de "zipped"
    df = pd.DataFrame(zipped)
#Renommer les colonnes du DataFrame avec les noms "pays" et "nom_poids"
    df.rename(columns={0: "pays", 1: nom_poids}, inplace=True)
#Ajouter le DataFrame à la liste "dfs"
    dfs.append(df.pivot_table(columns="pays"))
dfs
```

Out[47]:

```
[pays                Australia  Canada  France  Germany  Italy  Japan  \
 poids_Inscription           3       4       6        8      5      9

 pays                Netherlands  Saudi Arabia  United Kingdom  United States
 poids_Inscription             1             2               7             10  ,
 pays        Austria  Hong Kong SAR, China  Ireland  Netherlands  Norway  \
 poids_PIB         1                     5        3            2       8
```

```
pays        Saudi Arabia  Singapore  Switzerland  United Arab Emirates  \
poids_PIB              4         10            7                     9

pays        United States
poids_PIB               6  ,
pays             Canada  Denmark  Finland  Germany  Japan  Netherlands  Norway  \
poids_NET_USER        3        7        6        2      1            8      10

pays             Sweden  Switzerland  United Kingdom
poids_NET_USER        9            4               5  ,
pays               Australia  Canada  France  Germany  Italy  Japan  \
PoidsPop_Tot1524           2       3       6        8      5      9

pays               Netherlands  Saudi Arabia  United Kingdom  United States
PoidsPop_Tot1524             1             4               7             10  ]
```

In [48]:

```
#Concaténer toutes les trames de données en un seul DataFrame et remplacer les valeurs m
df_total = pd.concat(dfs, axis=0)
df_total = df_total.fillna(0)
df_total
```

Out[48]:

pays	Australia	Canada	France	Germany	Italy	Japan	Netherlands	Saudi Arabia	United Kingdom	United States	Au
poids_Inscription	3.0	4.0	6.0	8.0	5.0	9.0	1	2.0	7.0	10.0	
poids_PIB	0.0	0.0	0.0	0.0	0.0	0.0	2	4.0	0.0	6.0	
poids_NET_USER	0.0	3.0	0.0	2.0	0.0	1.0	8	0.0	5.0	0.0	
PoidsPop_Tot1524	2.0	3.0	6.0	8.0	5.0	9.0	1	4.0	7.0	10.0	

Etape 3

In [49]:

```
import numpy as np
import itertools

# Convertir df_total en une matrice numpy pour faciliter les calculs
pays_matrix = df_total.to_numpy()


# Initialiser une liste vide pour stocker les poids
poids_ind = []

# Générer toutes les permutations possibles de poids [1, 2, 3, 4]
for i in list(itertools.permutations([1, 2, 3,4])):
# Convertir les permutations en tableau numpy
    array_i= np.array(i)
    # Ajouter chaque combinaison de poids à la liste poids_ind
    poids_ind.append(array_i)
poids_ind
```

Out[49]:

```
[array([1, 2, 3, 4]),
 array([1, 2, 4, 3]),
 array([1, 3, 2, 4]),
 array([1, 3, 4, 2]),
 array([1, 4, 2, 3]),
 array([1, 4, 3, 2]),
 array([2, 1, 3, 4]),
 array([2, 1, 4, 3]),
 array([2, 3, 1, 4]),
 array([2, 3, 4, 1]),
```

```
 array([2, 4, 1, 3]),
 array([2, 4, 3, 1]),
 array([3, 1, 2, 4]),
 array([3, 1, 4, 2]),
 array([3, 2, 1, 4]),
 array([3, 2, 4, 1]),
 array([3, 4, 1, 2]),
 array([3, 4, 2, 1]),
 array([4, 1, 2, 3]),
 array([4, 1, 3, 2]),
 array([4, 2, 1, 3]),
 array([4, 2, 3, 1]),
 array([4, 3, 1, 2]),
 array([4, 3, 2, 1])]
```

In [50]:

```python
# Initialiser une liste vide pour stocker les résultats
resultat = []

# Boucler sur les poids pour effectuer le produit matriciel entre les poids et la matric

for i in poids_ind:
    # Calculer le produit matriciel
    produit = i.dot(pays_matrix)
    # Ajouter le produit matriciel à la liste des résultats
    resultat.append(produit)

# Afficher les résultats
resultat
```

Out[50]:

```
[array([11., 25., 30., 46., 25., 48., 33., 26., 50., 62.,  2., 10.,  6.,
        46., 20., 26., 18., 21., 18., 27.]),
 array([ 9., 25., 24., 40., 20., 40., 40., 22., 48., 52.,  2., 10.,  6.,
        56., 20., 30., 18., 28., 24., 36.]),
 array([11., 22., 30., 44., 25., 47., 27., 30., 45., 68.,  3., 15.,  9.,
        44., 30., 29., 27., 14., 12., 18.]),
 array([ 7., 22., 18., 32., 15., 31., 41., 22., 41., 48.,  3., 15.,  9.,
        64., 30., 37., 27., 28., 24., 36.]),
 array([ 9., 19., 24., 36., 20., 38., 28., 30., 38., 64.,  4., 20., 12.,
        52., 40., 36., 36., 14., 12., 18.]),
 array([ 7., 19., 18., 30., 15., 30., 35., 26., 36., 54.,  4., 20., 12.,
        62., 40., 40., 36., 21., 18., 27.]),
 array([14., 29., 36., 54., 30., 57., 32., 24., 57., 66.,  1.,  5.,  3.,
        38., 10., 19.,  9., 21., 18., 27.]),
 array([12., 29., 30., 48., 25., 49., 39., 20., 55., 56.,  1.,  5.,  3.,
        48., 10., 23.,  9., 28., 24., 36.]),
 array([14., 23., 36., 50., 30., 55., 20., 32., 47., 78.,  3., 15.,  9.,
        34., 30., 25., 27.,  7.,  6.,  9.]),
 array([ 8., 23., 18., 32., 15., 31., 41., 20., 41., 48.,  3., 15.,  9.,
        64., 30., 37., 27., 28., 24., 36.]),
 array([12., 20., 30., 42., 25., 46., 21., 32., 40., 74.,  4., 20., 12.,
        42., 40., 32., 36.,  7.,  6.,  9.]),
 array([ 8., 20., 18., 30., 15., 30., 35., 24., 36., 54.,  4., 20., 12.,
        62., 40., 40., 36., 21., 18., 27.]),
 array([17., 30., 42., 60., 35., 65., 25., 26., 59., 76.,  1.,  5.,  3.,
        28., 10., 15.,  9., 14., 12., 18.]),
 array([13., 30., 30., 48., 25., 49., 39., 18., 55., 56.,  1.,  5.,  3.,
        48., 10., 23.,  9., 28., 24., 36.]),
 array([17., 27., 42., 58., 35., 64., 19., 30., 54., 82.,  2., 10.,  6.,
        26., 20., 18., 18.,  7.,  6.,  9.]),
 array([11., 27., 24., 40., 20., 40., 40., 18., 48., 52.,  2., 10.,  6.,
        56., 20., 30., 18., 28., 24., 36.]),
 array([13., 21., 30., 42., 25., 46., 21., 30., 40., 74.,  4., 20., 12.,
        42., 40., 32., 36.,  7.,  6.,  9.]),
 array([11., 21., 24., 36., 20., 38., 28., 26., 38., 64.,  4., 20., 12.,
        52., 40., 36., 36., 14., 12., 18.]),
 array([18., 31., 42., 60., 35., 65., 25., 24., 59., 76.,  1.,  5.,  3.,
```

```
        28., 10., 15.,  9., 14., 12., 18.]),
 array([16., 31., 36., 54., 30., 57., 32., 20., 57., 66.,  1.,  5.,  3.,
        38., 10., 19.,  9., 21., 18., 27.]),
 array([18., 28., 42., 58., 35., 64., 19., 28., 54., 82.,  2., 10.,  6.,
        26., 20., 18., 18.,  7.,  6.,  9.]),
 array([14., 28., 30., 46., 25., 48., 33., 20., 50., 62.,  2., 10.,  6.,
        46., 20., 26., 18., 21., 18., 27.]),
 array([16., 25., 36., 50., 30., 55., 20., 28., 47., 78.,  3., 15.,  9.,
        34., 30., 25., 27.,  7.,  6.,  9.]),
 array([14., 25., 30., 44., 25., 47., 27., 24., 45., 68.,  3., 15.,  9.,
        44., 30., 29., 27., 14., 12., 18.])]
```

Etape 4

In [51]:

```python
# Création du dataFrame Grille_notation pour stocker les résultats de notation
Grille_notation=pd.DataFrame(resultat, columns=['Australia','Canada','France','Germany',
                                                'Saudi Arabia','United Kingdom','United Sta
                                                'Ireland','Norway','Singapore','Switzerland
                                                'Finland','Sweden'])

Grille_notation
```

Out[51]:

	Australia	Canada	France	Germany	Italy	Japan	Netherlands	Saudi Arabia	United Kingdom	United States	Austria	Hong Kong SAR China	Ir
0	11.0	25.0	30.0	46.0	25.0	48.0	33.0	26.0	50.0	62.0	2.0	10.0	
1	9.0	25.0	24.0	40.0	20.0	40.0	40.0	22.0	48.0	52.0	2.0	10.0	
2	11.0	22.0	30.0	44.0	25.0	47.0	27.0	30.0	45.0	68.0	3.0	15.0	
3	7.0	22.0	18.0	32.0	15.0	31.0	41.0	22.0	41.0	48.0	3.0	15.0	
4	9.0	19.0	24.0	36.0	20.0	38.0	28.0	30.0	38.0	64.0	4.0	20.0	
5	7.0	19.0	18.0	30.0	15.0	30.0	35.0	26.0	36.0	54.0	4.0	20.0	
6	14.0	29.0	36.0	54.0	30.0	57.0	32.0	24.0	57.0	66.0	1.0	5.0	
7	12.0	29.0	30.0	48.0	25.0	49.0	39.0	20.0	55.0	56.0	1.0	5.0	
8	14.0	23.0	36.0	50.0	30.0	55.0	20.0	32.0	47.0	78.0	3.0	15.0	
9	8.0	23.0	18.0	32.0	15.0	31.0	41.0	20.0	41.0	48.0	3.0	15.0	
10	12.0	20.0	30.0	42.0	25.0	46.0	21.0	32.0	40.0	74.0	4.0	20.0	
11	8.0	20.0	18.0	30.0	15.0	30.0	35.0	24.0	36.0	54.0	4.0	20.0	
12	17.0	30.0	42.0	60.0	35.0	65.0	25.0	26.0	59.0	76.0	1.0	5.0	
13	13.0	30.0	30.0	48.0	25.0	49.0	39.0	18.0	55.0	56.0	1.0	5.0	
14	17.0	27.0	42.0	58.0	35.0	64.0	19.0	30.0	54.0	82.0	2.0	10.0	
15	11.0	27.0	24.0	40.0	20.0	40.0	40.0	18.0	48.0	52.0	2.0	10.0	
16	13.0	21.0	30.0	42.0	25.0	46.0	21.0	30.0	40.0	74.0	4.0	20.0	
17	11.0	21.0	24.0	36.0	20.0	38.0	28.0	26.0	38.0	64.0	4.0	20.0	
18	18.0	31.0	42.0	60.0	35.0	65.0	25.0	24.0	59.0	76.0	1.0	5.0	
19	16.0	31.0	36.0	54.0	30.0	57.0	32.0	20.0	57.0	66.0	1.0	5.0	
20	18.0	28.0	42.0	58.0	35.0	64.0	19.0	28.0	54.0	82.0	2.0	10.0	
21	14.0	28.0	30.0	46.0	25.0	48.0	33.0	20.0	50.0	62.0	2.0	10.0	

22	16.0	25.0	36.0	50.0	30.0	55.0	20.0	28.0	47.0	78.0	3.0	15.0
23	14.0	25.0	30.0	44.0	25.0	47.0	27.0	24.0	45.0	68.0	3.0	15.0

In [52]:
```
#en sommant les point de tout les classements nous obtenons une sorte de classement moye

# Calcule la moyenne des valeurs pour chaque colonne dans Grille_notation,
#trier les valeurs par ordre décroissant,selectionner les 10 premières valeurs
classement=Grille_notation.mean(axis=0).sort_values(ascending=False).head(10)
# Convertir  en DataFrame
classement= pd.DataFrame(classement)
# Réinitialiser l'index,  renommer les colonnes en 'pays' et'note_finale'
classement=classement.reset_index().rename(columns={'index':'pays', 0: 'note_finale'})
classement
```

Out[52]:

	pays	note_finale
0	United States	65.0
1	Japan	47.5
2	United Kingdom	47.5
3	Germany	45.0
4	Norway	45.0
5	France	30.0
6	Netherlands	30.0
7	Switzerland	27.5
8	Italy	25.0
9	Saudi Arabia	25.0

6.Géo localisation

In [53]:
```
import matplotlib.pyplot as plt
# Importation de la bibliothèque folium pour la création de cartes interactives
import folium
# Importation de l'élément Figure de la bibliothèque branca
from branca.element import Figure

#Top 5 des pays par indicateur
fig=Figure(width=900,height=500)

# Création d'une carte centrée  avec un zoom de départ de 2
m=folium.Map(location=[38.9423133,34.9165444], tiles='cartodbpositron',zoom_start=2)
# Ajout de la carte à l'objet Figure
fig.add_child(m)



#Norway 64.58301349999999,17.86410976037601
folium.Marker(location=[64.5731537, 11.5280364],
              tooltip='<strong>en n°5 Norway</strong>',
              icon=folium.Icon(color='red',icon='info-sign')).add_to(m)

#Germany 51.1657065,10.452764000000002
folium.Marker(location=[51.1657065, 10.452764000000002],
             tooltip='<strong>en n°4 Germany</strong>',
              icon=folium.Icon(color='red',icon='info-sign')).add_to(m)
```

```
#United Kingdom 54.633221000000006,-3.432277499999998
folium.Marker(location=[54.633221000000006, -3.432277499999998],
              tooltip='<strong>en n°3 United Kingdom</strong>',
              icon=folium.Icon(color='red',icon='info-sign')).add_to(m)


#United States 36.966428,-95.844032
folium.Marker(location=[36.966428, -95.844032],
              tooltip='<strong>en n°1 United States</strong>',
              icon=folium.Icon(color='red',icon='info-sign')).add_to(m)

#Japan 34.886306,134.379711
folium.Marker(location=[34.886306, 134.379711],
              tooltip='<strong>en n°2 Japan</strong>',
              icon=folium.Icon(color='red',icon='info-sign')).add_to(m)


# Affichage de la carte avec les marqueurs ajoutés
m
```

Out[53]:

7. Conclusion.

In [54]:

```
#Top 5 des pays par indicateur
classement.head(5)
```

Out[54]:

	pays	note_finale
0	United States	65.0
1	Japan	47.5

2	United Kingdom	47.5
3	Germany	45.0
4	Norway	45.0

In [ ]:

```
```

In [ ]:

```
```