Projet 2

Analysez des données de systèmes éducatifs

Évaluateur:
M. Mohamed Sfina

Réalisé par
Stéphane Barré
Encadré par
M. Mahmoud Albardan

Vendredi 20 janvier 2023

Plan

- Présentation du projet
- Le jeu de données
- Séquence de filtrage des données
- Normalisation
- Méthode de classement des pays
- Géo localisation
- Perspectives et Conclusion

Présentation du projet

Objectif du projet:

Réaliser une analyse pré-exploratoire de données de systèmes éducatifs de la Banque Mondiale pour déterminer un projet d'expansion de notre start-up à l'international

Les informations à collecter de cette étude sont:

- Quels sont les pays avec un fort potentiel de clients pour nos services?
- Dans quels pays l'entreprise doit-elle opérer en priorité?

Présentation du jeu de données

Jeu de données

EdStatsCountry :241 lignes 32 colonnes
Informations géographiques économiques telles que les pays, les régions, le groupe de revenu…

EdStatsSeries: 3 665 lignes 21 colonnes
Informations détaillées sur les 3665 indicateurs de la banque mondiale et leurs méthodes de calcul.

EdStatsCountry-Series: 613 lignes 4 colonnes
Relatif aux code de pays et ses codes indicateurs avec les références des sources

EdStatsFootNote: 643 638 lignes 5 colonnes
notes sur les MAJ sur certains (1558) indicateurs par pays et par années.

EdStatsData: 886 930 lignes70 colonnes
Données relatives aux 3665 indicateurs mesurés sur 242 pays depuis 1970 ainsi que des projections jusqu'à 2100.

Séquence de Filtrage des données

Les phases de filtrage

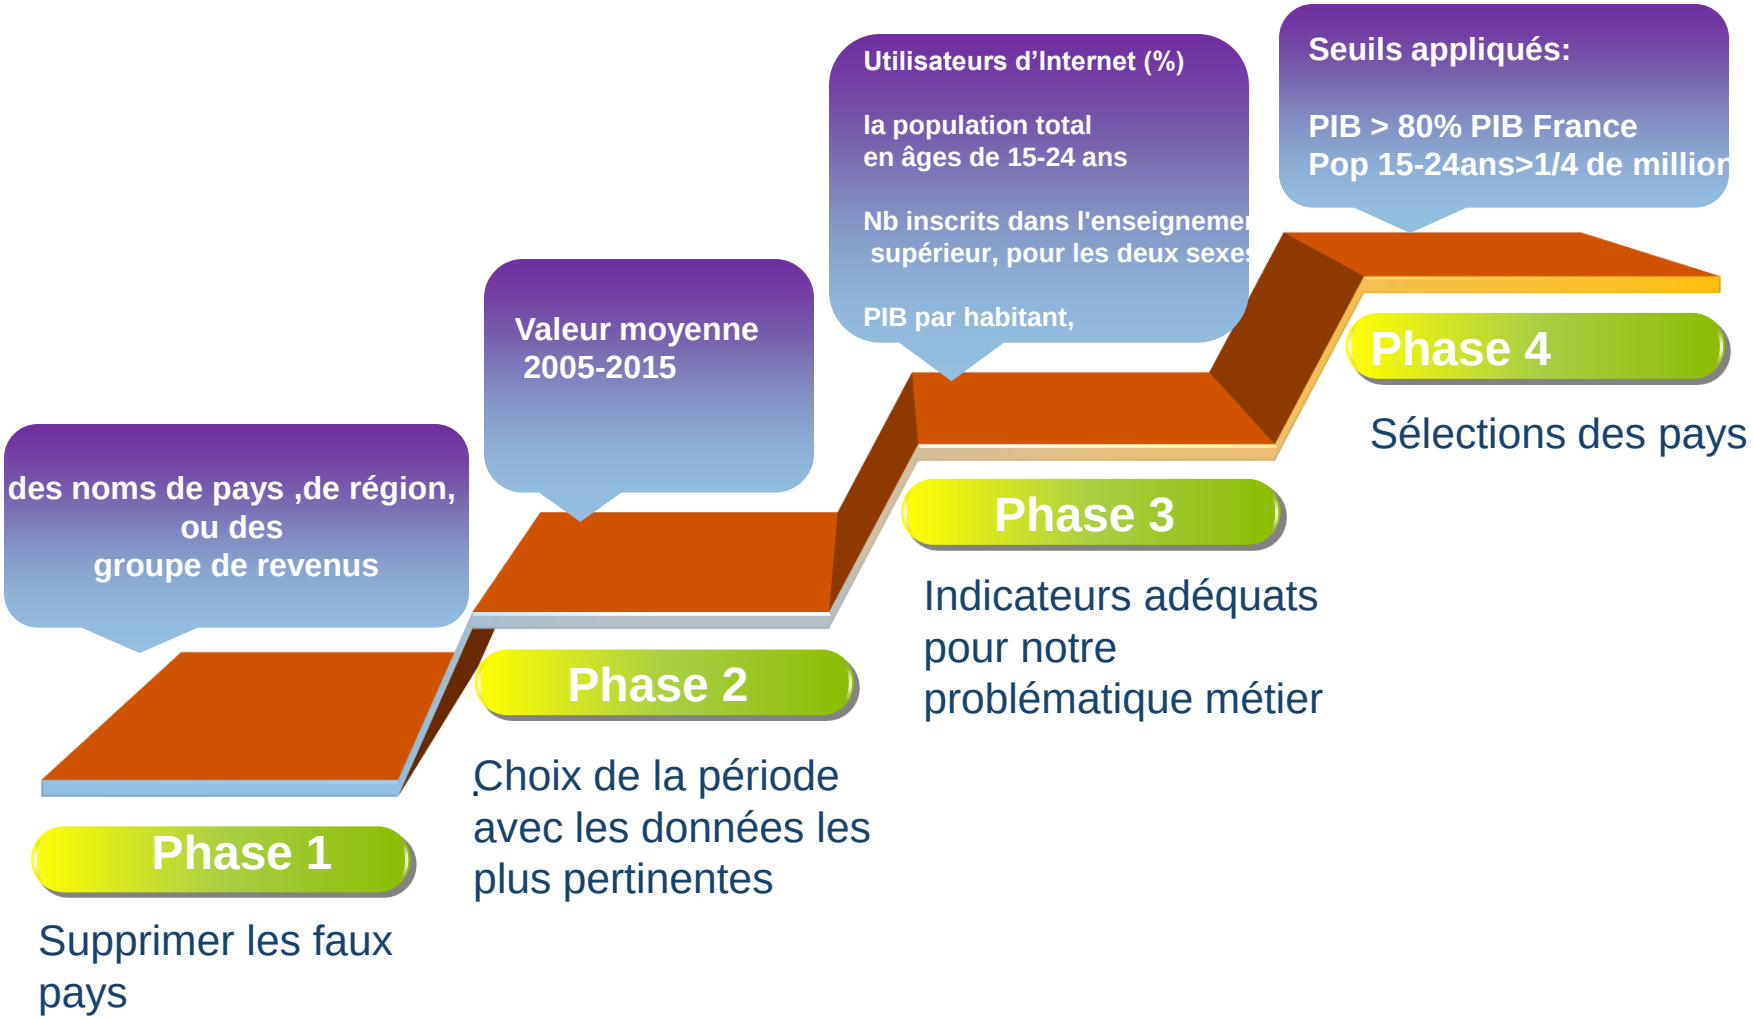

Suppression des faux pays

Le dataset principal contient de 242 pays/faux pays et 3665 indicateurs pour chacun de ces pays/faux pays.
Ces données sont réparties de 1970 à 2017, puis une projection pour la période 2020 –2100 par tranche de 5 ans

le dataset principal possède 70 colonnes et 886930 lignes organisées comme ci-dessous

25 x 3365 = 91625 lignes

217 x 3365 = 795305 lignes

	Country Name	Country Code	Indicator Name	Indicator Code	1970	1971	1972	1973	1974	1975	...	2060	2065	2070	2075	2080	2085	20
0	Arab World	ARB	Adjusted net enrolment rate, lower secondary,								...	NaN	NaN	NaN	NaN	NaN	NaN	Na
...	...	...	...															
91624	World	WLD	Youth literacy rate, population 15-24 years, m...	SE.ADT.1524.LT.MA.ZS	NaN	NaN	NaN	NaN	NaN	NaN	...	NaN	NaN	NaN	NaN	NaN	NaN	Na
91625	Afghanistan	AFG	Adjusted net enrolment rate, lower secondary,	UIS.NERA.2	NaN	NaN	NaN	NaN	7.05911	NaN	...	NaN	NaN	NaN	NaN	NaN	NaN	NaN	N
...	...	...	...															
886929	Zimbabwe	ZWE	Youth literacy rate, population 15-24 years, m...	SE.ADT.1524.LT.MA.ZS	NaN	NaN	NaN	NaN	NaN	NaN	...	NaN	NaN	NaN	NaN	NaN	NaN	NaN	NaN

```
#conserver les pays
#Sélectionner les lignes à partir de l'index 91625
data_pays_select= data.loc[91625:,:]
```

795305 lignes/ 3665 ind = 217 pays

Choix de la période avec les données les plus pertinentes

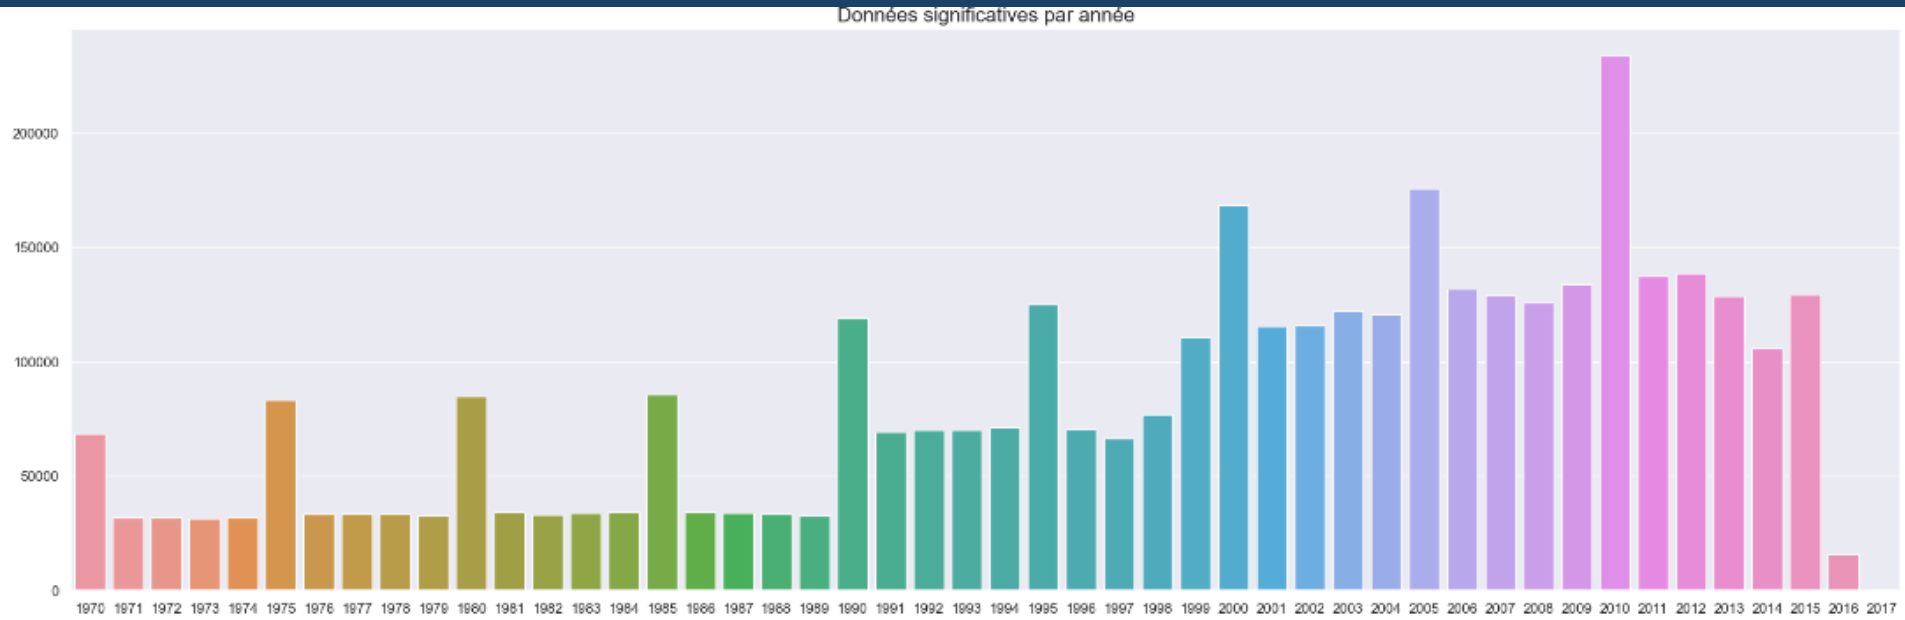

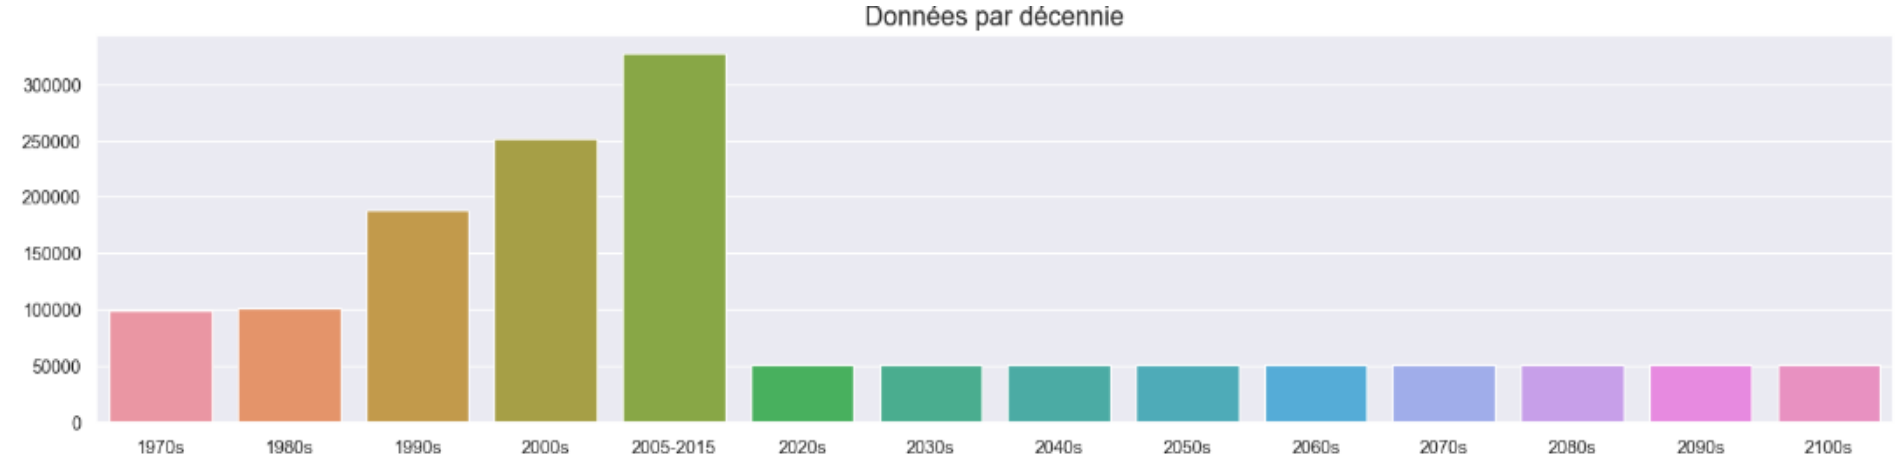

Indicateurs adéquats pour notre problématique

SE.TER.ENRR

Indicateurs éducatifs

Inscriptions dans l'enseignement supérieur, tous programmes, les deux sexes (nombre): dénommé Inscription

SP.POP.1524.TO.UN

Indicateur démographique

Population âgée de 15 à 24 ans, total dénommé: Pop.Tot1524

NY.GDP.PCAP.PP.CD

Indicateur économique

PIB par habitant, PPA ($ international courant): dénommé PIB

IT.NET.USER.P2

Indicateur numérique

Utilisateurs d'Internet (pour 100 personnes) dénommé: NET.USER

Sélection des pays

```
df_seuil_PIB_POP = data_pays.loc [((data_pays['PIB'] >=  32873) & (data_pays['Pop.Tot1524' ] >=500000))]
```

	Pays	Inscription	PIB	NET.USER	Pop.Tot1524
10	Australia	1.227505e+06	39703.799055	74.631119	2891825.9
11	Austria	3.283950e+05	42424.715781	73.284461	1001962.0
18	Belgium	4.374370e+05	39376.870780	72.048019	1259041.1
35	Canada	1.622693e+06	40557.236537	79.348000	4443212.6
52	Denmark	2.525646e+05	41899.681838	88.768973	657582.6
65	Finland	3.066367e+05	38482.395465	84.460479	653210.9
66				80	7663754.7
71				00	9393699.1
84	Hong Kong SA			27	887453.6
91				99	606023.7
93				76	5821794.0
95				11	12921826.9
136	Netherlands	6.475139e+05	44632.015920	88.819305	1987072.4
142	Norway	2.288138e+05	59352.288863	90.700336	615806.9
143	Oman	7.729478e+04	41996.265428	35.896110	564948.8
161	Saudi Arabia	9.371469e+05	46023.909937	40.387825	4853746.7
166	Singapore	2.219153e+05	69369.411362	70.183129	634866.4
182	Sweden	4.330436e+05	41574.366613	89.885357	1186952.4
183	Switzerland	2.421074e+05	52894.263980	81.153303	940874.6
199	United Arab Emirates	1.087372e+05	67426.982168	68.939999	691985.5
200	United Kingdom	2.393757e+06	36368.964439	81.517410	7955471.5
201	United States	1.919801e+07	49120.975228	71.741871	44573903.0

22 pays en liste

Normalisation

```
min_max_scaler = preprocessing.MinMaxScaler(feature_range =(0, 1))
```

```
df_ind_apres_min_max_scaler = min_max_scaler.fit_transform(x)
df_ind_apres_min_max_scaler=x_apres_min_max_scaler.round(1)
```

```
APRES min max Scaling
 [[0.1 0.1 0.7 0.1]
 [0.   0.2 0.7 0.  ]
 [0.   0.1 0.7 0.  ]
 [0.1 0.2 0.8 0.1]
 [0.   0.2 1.   0.  ]
 [0.   0.1 0.9 0.  ]
 [0.1 0.   0.6 0.2]
 [0.1 0.1 0.8 0.2]
 [0.   0.3 0.6 0.  ]
 [0.   0.3 0.6 0.  ]
 [0.1 0.   0.2 0.1]
 [0.2 0.   0.8 0.3]
 [0.   0.3 1.   0.  ]
 [0.   0.7 1.   0.  ]
 [0.   0.2 0.   0.  ]
 [0.   0.3 0.1 0.1]
 [0.   1.   0.6 0.  ]
 [0.   0.2 1.   0.  ]
 [0.   0.5 0.8 0.  ]
 [0.   0.9 0.6 0.  ]
 [0.1 0.   0.8 0.2]
 [1.   0.4 0.7 1.  ]]
```

Inscription	PIB	NET.USER	Pop.Tot1524
1.227505e+06	39703.799055	74.631119	2891825.9
3.283950e+05	42424.715781	73.284461	1001962.0
4.374370e+05	39376.870780	72.048019	1259041.1
1.622693e+06	40557.236537	79.348000	4443212.6
2.525646e+05	41899.681838	88.768973	657582.6
3.066367e+05	38482.395465	84.460479	653210.9

```
APRES min max Scaling :
 [[0.1 0.1 0.7 0.1]
 [0.   0.2 0.7 0.  ]
 [0.   0.1 0.7 0.  ]
 [0.1 0.2 0.8 0.1]
 [0.   0.2 1.   0.  ]
 [0.   0.1 0.9 0.  ]
```

Méthode de classement des pays

Les etapes :

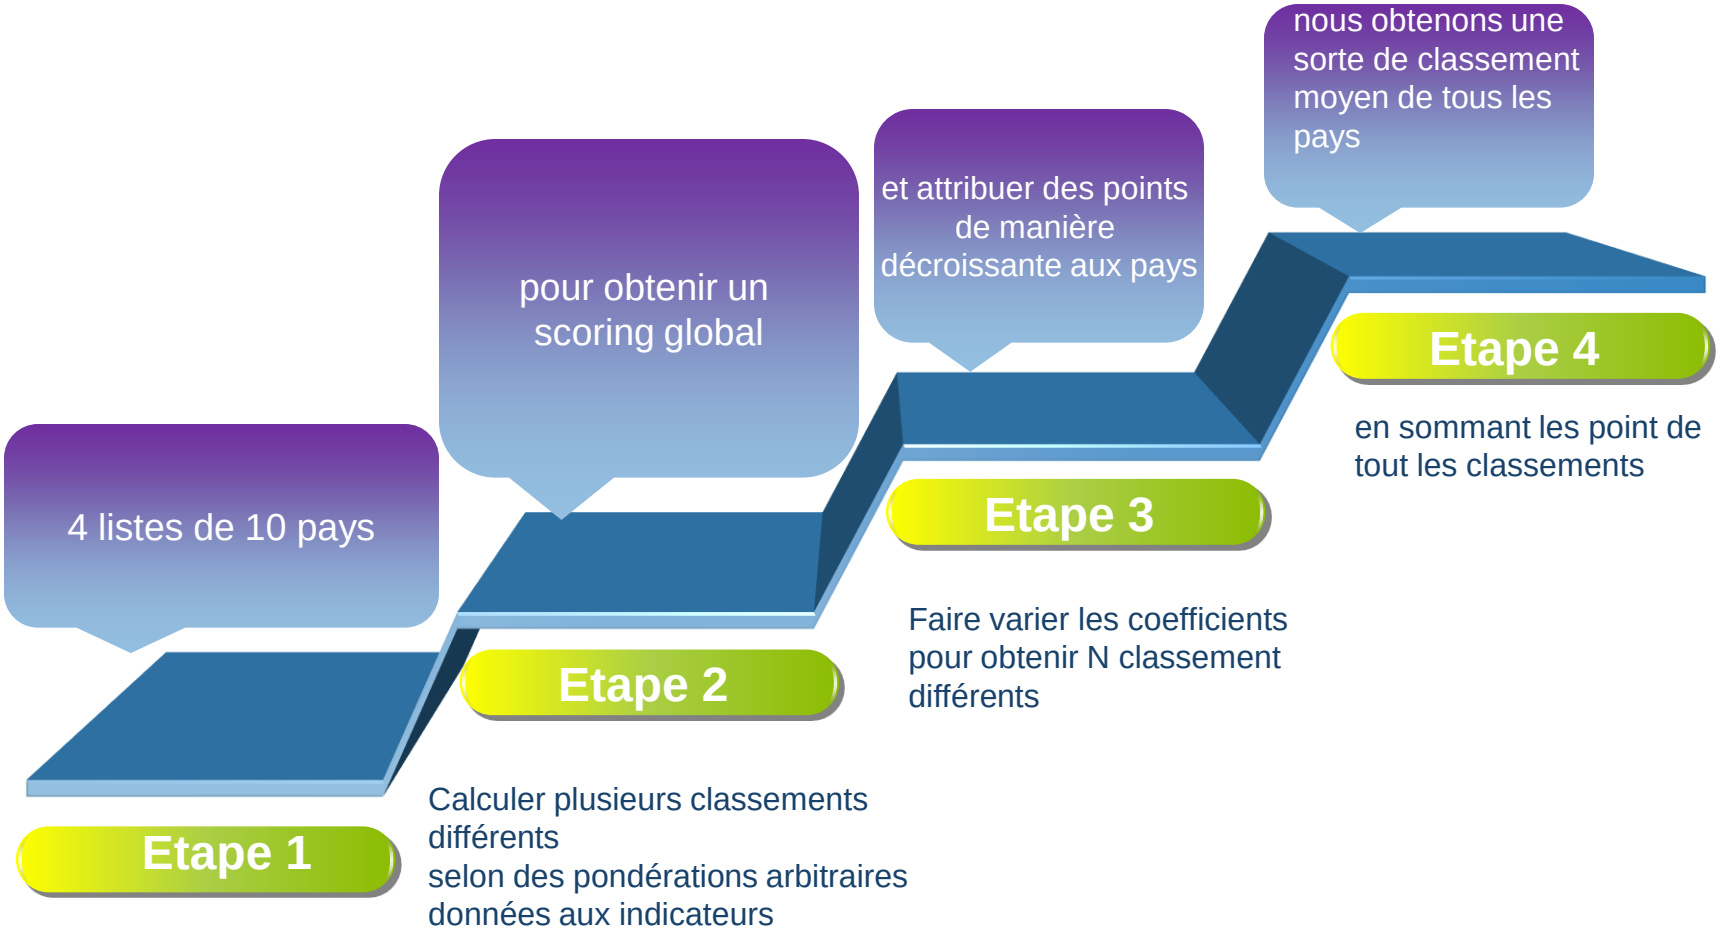

Trier les 10 meilleurs pays selon chaque indicateur

Calculer plusieurs classements différents
selon des pondérations arbitraires données aux indicateurs

Faire varier les coefficients pour obtenir N classement différents

en sommant les point de tout les classements

Méthode de classement des pays

Etape 1: top 10 des pays par indicateurs

Pays avec le plus grand nombre d'inscription sup: ['United States' 'Japan' 'Germany' 'United Kingdom' 'France' 'Italy' 'Canada' 'Australia' 'Saudi Arabia' 'Netherlands']

Pays avec le meilleur PIB: ['Singapore' 'United Arab Emirates' 'Norway' 'Switzerland' 'United States' 'Hong Kong SAR, China' 'Saudi Arabia' 'Ireland' 'Netherlands' 'Austria']

Pays avec le meilleur taux d'utilisateur internet: ['Norway' 'Sweden' 'Netherlands' 'Denmark' 'Finland' 'United Kingdom' 'Switzerland' 'Canada' 'Germany' 'Japan']

Pays avec le plus grand nombre 15/24 ans: ['United States' 'Japan' 'Germany' 'United Kingdom' 'France' 'Italy' 'Saudi Arabia' 'Canada' 'Australia' 'Netherlands']

Mais quels pays choisir parmi ces listes de pays?

Méthode de classement des pays

Etape 2

Calculer plusieurs classements différents selon des pondérations arbitraires données aux indicateurs

```
dfs = []
for nom_ind, données, nom_poids in lists:
    poids = list(range(len(données), 0, -1))
    zipped = list(zip(données, poids))
    df = pd.DataFrame(zipped)
    df.rename(columns={0: "pays", 1: nom_poids}, inplace=True)
    dfs.append(df.pivot_table(columns="pays"))
```

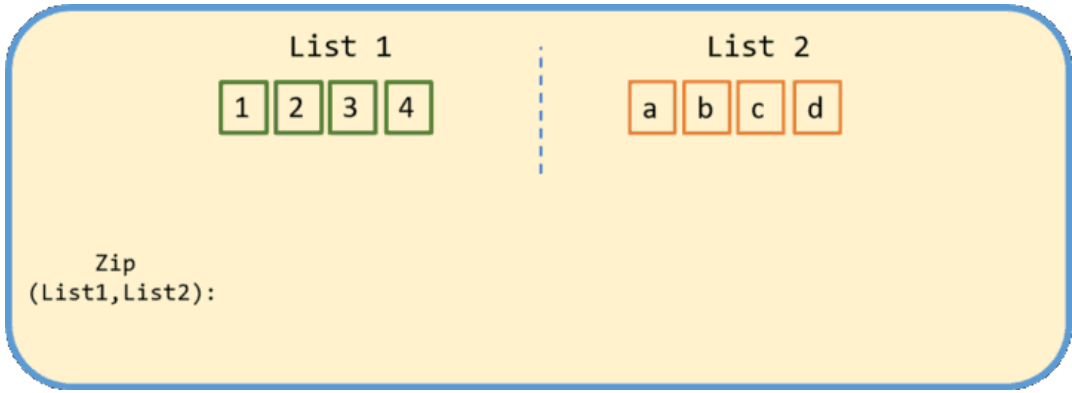

poids	Australia	Canada	France	Germany	Italy	Japan	Netherlands	Saudi Arabia	United Kingdom	United States	Austria	Kong SAR, China	Ireland	Norway	Singapore
Poids_Inscription	3.0	4.0	6.0	8.0	5.0	9.0	1	2.0	7.0	10.0	0.0	0.0	0.0	0.0	0.0
Poids_PIB	0.0	0.0	0.0	0.0	0.0	0.0	2	4.0	0.0	6.0	1.0	5.0	3.0	8.0	10.0
Poids_NETUSER	0.0	3.0	0.0	2.0	0.0	1.0	8	0.0	5.0	0.0	0.0	0.0	0.0	10.0	0.0
PoidsPop_Tot1524	2.0	3.0	6.0	8.0	5.0	9.0	1	4.0	7.0	10.0	0.0	0.0	0.0	0.0	0.0

Méthode de classement des pays

Etape 3

Faire varier les coefficients pour obtenir N classement différents et attribuer des points de manière décroissante aux pays.

```
import itertools
poids_ind = []
for i in list(itertools.permutations([1, 2, 3, 4])):
    array_i= np.array(i)
    poids_ind.append(array_i)
```

```
resultat = []
for i in poids:
    produit = i.dot(pays_matrix)
    resultat.append(produit)
```

```
poids_ind
```

```
[array([1, 2, 3, 4]),
 array([1, 2, 4, 3]),
 array([1, 3, 2, 4]),
 array([1, 3, 4, 2]),
 array([1, 4, 2, 3]),
 array([1, 4, 3, 2]),
 array([2, 1, 3, 4]),
 array([2, 1, 4, 3]),
 array([2, 3, 1, 4]),
 array([2, 3, 4, 1]),
 array([2, 4, 1, 3]),
 array([2, 4, 3, 1]),
 array([3, 1, 2, 4]),
 array([3, 1, 4, 2]),
 array([3, 2, 1, 4]),
 array([3, 2, 4, 1]),
 array([3, 4, 1, 2]),
 array([3, 4, 2, 1]),
 array([4, 1, 2, 3]),
 array([4, 1, 3, 2]),
 array([4, 2, 1, 3]),
 array([4, 2, 3, 1]),
 array([4, 3, 1, 2]),
 array([4, 3, 2, 1])]
```

```
[array([11., 25., 30., 46., 25., 48., 33., 26., 50., 62.,  2., 10.,  6.,
        46., 20., 26., 18., 21., 18., 27.]),
 array([ 9., 25., 24., 40., 20., 40., 40., 22., 48., 52.,  2., 10.,  6.,
        56., 20., 30., 18., 28., 24., 36.]),
 array([11., 22., 30., 44., 25., 47., 27., 30., 45., 68.,  3., 15.,  9.,
        44., 30., 29., 27., 14., 12., 18.]),
 array([ 7., 22., 18., 32., 15., 31., 41., 22., 41., 48.,  3., 15.,  9.,
        64., 30., 37., 27., 28., 24., 36.]),
 array([ 9., 19., 24., 36., 20., 38., 28., 30., 38., 64.,  4., 20., 12.,
        52., 40., 36., 36., 14., 12., 18.]),
 array([ 7., 19., 18., 30., 15., 30., 35., 26., 36., 54.,  4., 20., 12.,
        62., 40., 40., 36., 21., 18., 27.]),
 array([14., 29., 36., 54., 30., 57., 32., 24., 57., 66.,  1.,  5.,  3.,
        38., 10., 19.,  9., 21., 18., 27.]),
 array([12., 29., 30., 48., 25., 49., 39., 20., 55., 56.,  1.,  5.,  3.,
        48., 10., 23.,  9., 28., 24., 36.]),
 array([14., 23., 36., 50., 30., 55., 20., 32., 47., 78.,  3., 15.,  9.,
        34., 30., 25., 27.,  7.,  6.,  9.]),
 array([ 8., 23., 18., 32., 15., 31., 41., 20., 41., 48.,  3., 15.,  9.,
```

Méthode de classement des pays

Chaque ligne du DataFrame représente les résultats de la multiplication matricielle

	Australia	Canada	France	Germany	Italy	Japan	Netherlands	Saudi Arabia	United Kingdom	United States	Austria	Hong Kong SAR China	Ireland	Norway	Singapore	Switzerland	United Arab Emirate
0	11.0	25.0	30.0	46.0	25.0	48.0	33.0	26.0	50.0	62.0	2.0	10.0	6.0	46.0	20.0	26.0	18.
1	9.0	25.0	24.0	40.0	20.0	40.0	40.0	22.0	48.0	52.0	2.0	10.0	6.0	56.0	20.0	30.0	18.
2	11.0	22.0	30.0	44.0	25.0	47.0	27.0	30.0	45.0	68.0	3.0	15.0	9.0	44.0	30.0	29.0	27.
3	7.0	22.0	18.0	32.0	15.0	31.0	41.0	22.0	41.0	48.0	3.0	15.0	9.0	64.0	30.0	37.0	27.
4	9.0	19.0	24.0	36.0	20.0	38.0	28.0	30.0	38.0	64.0	4.0	20.0	12.0	52.0	40.0	36.0	36.
...	...	...	...	...	...	...	...	...	...	...	...	...	...	...	...	...	.
91	16.0	31.0	36.0	54.0	30.0	57.0	32.0	20.0	57.0	66.0	1.0	5.0	3.0	38.0	10.0	19.0	9.
92	18.0	28.0	42.0	58.0	35.0	64.0	19.0	28.0	54.0	82.0	2.0	10.0	6.0	26.0	20.0	18.0	18.
93	14.0	28.0	30.0	46.0	25.0	48.0	33.0	20.0	50.0	62.0	2.0	10.0	6.0	46.0	20.0	26.0	18.
94	16.0	25.0	36.0	50.0	30.0	55.0	20.0	28.0	47.0	78.0	3.0	15.0	9.0	34.0	30.0	25.0	27.
95	14.0	25.0	30.0	44.0	25.0	47.0	27.0	24.0	45.0	68.0	3.0	15.0	9.0	44.0	30.0	29.0	27.

Méthode de classement des pays

Etape 4

en sommant les pointsde tout les classements nous obtenons une un classement moyen de tous les pays

	pays	note_finale
0	United States	65.0
1	Japan	47.5
2	United Kingdom	47.5
3	Germany	45.0
4	Norway	45.0
5	France	30.0
6	Netherlands	30.0
7	Switzerland	27.5
8	Italy	25.0
9	Saudi Arabia	25.0

Géo localisation du top 5 des pays

Perspectives et conclusion

- Dans ce projet, nous voulions étudier les perspectives possibles à moyen ou à long terme.

- les données mises à disposition ne fournissent pas suffisamment d’informations permettant de nous projeter dans le futur.

- Une étude par extrapolation pourrait être envisagée.

- Malgré, le taux élevé de données manquantes de certains indicateurs, les données de la banque mondiale fournissent assez d' informations pertinentes et variées pour le projet d'expansion de notre entreprise.

- Il en ressort que, les trois pays ayant un fort potentiel de clients pour nos services, relatif à la démographie, à l’éducation, au nombre d'utilisateurs d'internet et au PIB par habitant sont:

- Etats unis
- Japon
- Angleterre

Merci de votre attention